



Politechnika Łódzka

**Wydział Fizyki Technicznej, Informatyki
i Matematyki Stosowanej**

Nikodem Wojtczak

Nr albumu: 247823

PRACA DYPLOMOWA
inżynierska
na kierunku Informatyka Stosowana

**RiskScoop AI – system analizy ryzyka powodziowego
z wykorzystaniem agenta AI**

Instytut Informatyki I72

Promotor: dr Piotr Milczarski

ŁÓDŹ 2026

Spis treści

Wstęp	4
Cel i zakres pracy	6
1 Przegląd literatury i analiza istniejących rozwiązań	8
1.1 Agenci sztucznej inteligencji w analizie geoprzestrzennej	8
1.1.1 Koncepcja agentów AI	8
1.1.2 Przegląd istniejących frameworków	8
1.1.3 Framework Agno	9
1.2 Systemy monitorowania powodzi	9
1.2.1 Copernicus GloFAS	9
1.2.2 Copernicus Rapid Mapping	9
1.3 Otwarte dane geoprzestrzenne	9
1.3.1 Overture Maps Foundation	9
1.3.2 OpenStreetMap i Nominatim	10
1.4 Model oceny ryzyka powodziowego	10
1.5 Podsumowanie przeglądu literatury	10
1.6 Analiza istniejących rozwiązań	10
1.6.1 Platformy geoinformacyjne z interfejsem języka naturalnego	11
1.6.2 Platformy oceny ryzyka powodziowego	11
1.6.3 Prototypy akademickie	11
1.6.4 Analiza porównawcza	12
1.6.5 Identyfikacja luki rynkowej	12
1.7 Wymagania funkcjonalne i нефункционалне	12
2 Projekt systemu RiskScoop AI	15
2.1 Wymagania systemowe	15
2.1.1 Wymagania funkcjonalne	15
2.1.2 Wymagania нефункционалне	15
2.2 Architektura systemu	16
2.2.1 Architektura wysokopoziomowa	16
2.2.2 Wzorzec AgentOS	16
2.2.3 Diagram komponentów	17
2.3 Projekt agenta AI	17
2.3.1 Model językowy	17
2.3.2 Instrukcje systemowe	17
2.3.3 Persystencja sesji	18
2.4 Projekt narzędzi agenta	18

2.4.1	Narzędzie search_division	18
2.4.2	Narzędzie get_division	19
2.4.3	Narzędzie get_overture_data	19
2.4.4	Narzędzie get_flood_forecast	19
2.4.5	Narzędzie intersect_flood_zones	20
2.5	Projekt przepływu pracy	20
2.5.1	Diagram sekwencji	20
2.5.2	Fazy analizy	21
2.6	Projekt modelu ryzyka	21
2.6.1	Klasyfikacja ryzyka	21
2.6.2	Algorytm agregacji	21
2.7	Projekt interfejsu użytkownika	22
2.7.1	Komponenty UI	22
2.7.2	Interakcje użytkownika	22
2.8	Projekt integracji ze źródłami danych	22
2.8.1	OpenStreetMap / Nominatim	22
2.8.2	Overture Maps API	23
2.8.3	Copernicus GloFAS	23
2.9	Podsumowanie projektu	23
3	Implementacja systemu RiskScoop AI	24
3.1	Implementacja backendu	24
3.1.1	Konfiguracja AgentOS	24
3.1.2	Implementacja narzędzia get_division	24
3.1.3	Algorytm assemble_rings	24
3.1.4	Implementacja narzędzia get_overture_data	25
3.1.5	Implementacja narzędzia get_flood_forecast	25
3.1.6	Implementacja narzędzia intersect_flood_zones	26
3.2	Implementacja serwisów	27
3.2.1	LayerService	27
3.2.2	NominatimService	27
3.2.3	GloFASService	27
3.3	Implementacja frontendu	27
3.3.1	Architektura komponentów	27
3.3.2	Komunikacja z backendem	28
3.3.3	Wizualizacja warstw	28
3.4	Własne endpointy API	28
3.5	Przykłady użycia systemu	28
3.5.1	Przykład 1: Szpitale w Genewie	29

3.5.2	Przykład 2: Szkoły w Warszawie	29
3.5.3	Przykład 3: Budynki w Krakowie	30
3.5.4	Przykład 4: Infrastruktura w okolicach Płocka	31
3.5.5	Przykład 5: Infrastruktura we Wrocławiu	32
3.6	Podsumowanie implementacji	33
4	Testy i walidacja systemu	34
4.1	Metodologia testów	34
4.1.1	Środowisko testowe	34
4.1.2	Zakres testów	34
4.2	Testy funkcjonalne	34
4.2.1	Scenariusze testowe	34
4.3	Testy interpretacji języka naturalnego	35
4.3.1	Zbiór testowy	35
4.3.2	Wyniki testów NL	36
4.3.3	Analiza błędów	36
4.4	Testy wydajnościowe	37
4.4.1	Metodologia pomiaru	37
4.4.2	Wyniki pomiarów	37
4.4.3	Analiza wydajności	37
4.4.4	Rozkład czasu wykonania	38
4.5	Podsumowanie testów	38
	Wnioski	40
	Podsumowanie	40
	Spis rysunków	45
	Spis tabel	46
	Wykaz skrótów	47
	Wykaz definicji	48
	Wykaz załączników	49

Streszczenie

Celem pracy było zaprojektowanie i implementacja systemu RiskScoop AI – prototypu agenta AI do analizy ryzyka powodziowego dla infrastruktury krytycznej. System łączy przetwarzanie języka naturalnego z analizą geoprzestrzenną, umożliwiając zadawanie pytań dotyczących zagrożenia powodziowego.

Praca przedstawia przegląd literatury obejmujący agentów AI w analizie geoprzestrzennej oraz systemy Rapid Mapping. Zidentyfikowano lukę rynkową – brak narzędzi łączących interfejs języka naturalnego z analizą ryzyka powodziowego.

System integruje dane z Overture Maps Foundation (infrastruktura), Copernicus GloFAS (zagrożenie powodziowe) oraz model Gemini do interpretacji zapytań. Aplikacja webowa (Mapbox GL JS) wizualizuje wyniki na interaktywnej mapie z kwantyfikacją ryzyka.

Prototyp poddano testom funkcjonalnym i wydajnościowym. System obsługuje zapytania dotyczące kategorii infrastruktury (szpitale, szkoły, drogi), automatycznie tłumacząc je na operacje geoprzestrzenne. Wyniki prezentowane są na mapie z kodowaniem kolorystycznym poziomu ryzyka.

Praca ma zastosowanie w obszarze Rapid Mapping oraz wsparcia decyzyjnego dla służb reagowania kryzysowego.

Słowa kluczowe: agent AI analiza ryzyka powodziowego interfejs języka naturalnego infrastruktura krytyczna Rapid Mapping

Keywords: AI agent flood risk analysis natural language interface critical infrastructure Rapid Mapping

Wstęp

Powodzie stanowią jedno z najpoważniejszych zagrożeń naturalnych dla społeczeństw i infrastruktury na całym świecie. Według raportu Światowej Organizacji Meteorologicznej [17], w ciągu ostatnich dwóch dekad liczba katastrof związanych z wodą wzrosła o 70%, przy czym powodzie odpowiadają za największą liczbę ofiar śmiertelnych i strat ekonomicznych wśród wszystkich zjawisk hydrometeorologicznych. W kontekście zmian klimatycznych problem ten narasta – zwiększająca się częstotliwość ekstremalnych opadów deszczu oraz rosnący poziom mórz prowadzą do wzrostu ryzyka powodziowego w wielu regionach świata, w tym w Polsce i Europie [15].

Szczególnie podatna na zagrożenie powodziowe jest infrastruktura krytyczna, obejmująca szpitale, szkoły, drogi, mosty oraz inne obiekty użyteczności publicznej [9]. Zatopienie czy uszkodzenie takich obiektów może prowadzić do kaskadowych skutków dla całych społeczności – od braku dostępu do opieki medycznej, przez izolację komunikacyjną, po długotrwałe zakłócenia w funkcjonowaniu administracji lokalnej. Identyfikacja i kwantyfikacja ryzyka powodziowego dla infrastruktury krytycznej stanowi zatem kluczowy element zarządzania ryzykiem katastroficznym oraz planowania przestrzennego [2].

Tradycyjne podejścia do oceny ryzyka powodziowego opierają się na specjalistycznych systemach Geograficznych Systemów Informacyjnych (GIS), które wymagają wysokich kompetencji technicznych oraz znajomości skomplikowanych narzędzi analitycznych. Stanowi to istotną barierę dla potencjalnych użytkowników, szczególnie w kontekście Rapid Mapping – szybkiego mapowania sytuacji kryzysowej wymagającego wydania oceny ryzyka w ciągu godzin od zdarzenia. Służby reagowania kryzysowego, decydenci lokalni czy planiści przestrzenni często nie dysponują czasem ani zasobami na przeprowadzenie złożonych analiz geoprzestrzennych przy użyciu tradycyjnych narzędzi GIS.

W ostatnich latach rozwinęły się dwa kierunki technologiczne istotne dla tego problemu. Po pierwsze, metody uczenia maszynowego umożliwiają automatyzację przetwarzania danych satelitarnych i budowę modeli predykcyjnych ryzyka powodziowego [16]. Po drugie, duże modele językowe (Large Language Models, LLM) i agenci AI pozwalają na tworzenie interfejsów języka naturalnego, dzięki którym użytkownicy mogą zadawać pytania bez znajomości składni GIS czy języków programowania [10].

Jednocześnie rozwijają się otwarte źródła danych geoprzestrzennych. Program Copernicus Unii Europejskiej oferuje globalny system monitorowania powodzi (GloFAS) dostarczający prognoz i danych o zagrożeniu powodziowym w czasie rzeczywistym [8]. Overture Maps Foundation, inicjatywa wspierana przez wiodące firmy technologiczne (Amazon, Meta, Microsoft, TomTom), udostępnia dane o infrastrukturze globalnej, obejmujące 2,6 miliarda budynków, 64 miliony punktów użyteczności publicznej oraz 321 milionów segmentów drogowych [12].

Praca łączy te technologie w prototypowym systemie RiskScoop AI – agencie AI umożliwiającym analizę ryzyka powodziowego dla infrastruktury krytycznej poprzez zapytania w języku

naturalnym. Na rynku brakuje narzędzi łączących interfejs języka naturalnego z oceną ryzyka powodziowego dla infrastruktury krytycznej, szczególnie w kontekście Rapid Mapping. Rozwiązanie bazuje na osiągnięciach z dziedziny agentów geoprzestrzennych (ChatGeoAI, LLM-Find, GeoGPT) oraz otwartych europejskich źródłach danych (Copernicus GloFAS, Overture Maps).

Praca ma następującą strukturę. Rozdział pierwszy przedstawia przegląd literatury obejmujący agentów AI w analizie geoprzestrzennej, systemy monitorowania powodzi i otwarte dane geoprzestrzenne, a następnie analizę istniejących rozwiązań komercyjnych i akademickich wraz z identyfikacją luki rynkowej oraz wymagania funkcjonalne i нефunkcjonalne systemu. Rozdział drugi prezentuje projekt systemu, opisując architekturę, narzędzia agenta oraz model ryzyka. Rozdział trzeci omawia szczegóły implementacji backendu i frontendu. Rozdział czwarty przedstawia przeprowadzone testy funkcjonalne, wydajnościowe oraz testy interpretacji języka naturalnego wraz z analizą wyników. Pracę zamyka podsumowanie oraz wnioski dotyczące osiągniętych rezultatów i kierunków dalszego rozwoju systemu.

Prototyp stanowi dowód koncepcji (proof of concept) – użytkownik może zadać pytanie typu „Które szpitale w Warszawie są zagrożone powodzią?” i otrzymać wynik na mapie bez znajomości narzędzi GIS. System działa w przeglądarce i korzysta wyłącznie z otwartych źródeł danych.

Cel i zakres pracy

Cel główny pracy

Celem pracy jest zaprojektowanie i zaimplementowanie prototypu aplikacji webowej RiskScoop AI – systemu analizy ryzyka powodziowego dla infrastruktury krytycznej, wykorzystującego agenta AI do przetwarzania zapytań w języku naturalnym i generowania analiz geoprzestrzennych. System ma zastosowanie w obszarze Rapid Mapping, łącząc interfejs języka naturalnego z oceną ryzyka powodziowego.

Cele szczegółowe

W ramach realizacji celu głównego wyznaczono następujące cele szczegółowe:

1. **Analiza literatury** obejmująca:

- metody uczenia maszynowego w ocenie ryzyka powodziowego,
- agentów AI wykorzystujących interfejs języka naturalnego w analizie geoprzestrzennej (ChatGeoAI, LLM-Find, GeoGPT),
- systemy Rapid Mapping oraz Copernicus GloFAS,
- otwarte dane geoprzestrzenne (Overture Maps Foundation),
- technologie front-end dla aplikacji webowych (Mapbox GL JS).

2. **Przeprowadzenie analizy konkurencyjnych rozwiązań** na rynku systemów analizy geoprzestrzennej z interfejsem języka naturalnego oraz platform specjalizujących się w ocenie ryzyka powodziowego, w celu identyfikacji luk rynkowych i możliwości dla RiskScoop AI.

3. **Zaprojektowanie architektury systemu** RiskScoop AI obejmującej:

- komponent agenta AI do przetwarzania języka naturalnego,
- moduł integracji z bazą Overture Maps,
- moduł integracji z systemem Copernicus GloFAS,
- moduł kwantyfikacji ryzyka powodziowego,
- interfejs użytkownika z interaktywną wizualizacją mapową.

4. **Zaimplementowanie prototypu systemu** wykorzystującego:

- Vanilla JavaScript i Mapbox GL JS do wizualizacji geoprzestrzennej,
- backend obsługujący przetwarzanie zapytań i operacje geoprzestrzenne,
- integrację z modelami języka naturalnego (LLM).

5. **Przeprowadzenie testów funkcjonalnych i wydajnościowych** zaimplementowanego prototypu, weryfikujących:

- poprawność interpretacji zapytań w języku naturalnym,
- dokładność identyfikacji obiektów infrastrukturalnych,
- poprawność kwantyfikacji ryzyka powodziowego,
- wydajność systemu przy różnych obciążeniach.

1 Przegląd literatury i analiza istniejących rozwiązań

Rozdział przedstawia przegląd literatury w obszarach kluczowych dla systemu RiskScoop AI: agentów AI w analizie geoprzestrzennej, systemów monitorowania powodzi oraz otwartych danych geoprzestrzennych.

1.1 Agenci sztucznej inteligencji w analizie geoprzestrzennej

1.1.1 Koncepcja agentów AI

Agenty sztucznej inteligencji definiuje się jako autonomiczne systemy zdolne do percepcji otoczenia, podejmowania decyzji oraz wykonywania działań [7]. W kontekście analizy geoprzestrzennej, agenty AI pośredniczą między użytkownikiem formułującym zapytanie w języku naturalnym a złożonymi operacjami przetwarzania danych przestrzennych.

Architektura współczesnych agentów geoprzestrzennych opiera się na trzech komponentach:

- **Moduł percepcji** – rozumienie języka naturalnego i ekstrakcja parametrów
- **Moduł rozumowania** – planowanie sekwencji operacji geoprzestrzennych
- **Moduł działania** – wykonanie operacji i generowanie wyników

1.1.2 Przegląd istniejących frameworków

W literaturze opisano kilka frameworków agentów AI dla analiz geoprzestrzennych. **Chat-GeoAI** [10] wykorzystuje model Llama 2 do generowania kodu PyQGIS, osiągając wskaźnik sukcesu 76%. **LLM-Find** [6] specjalizuje się w autonomicznym wyszukiwaniu danych geoprzestrzennych z 80–90% skutecznością. **GeoGPT** [14] oferuje kompleksowe podejście end-to-end do analiz przestrzennych. Najnowszy **GeoAgent** [11] integruje Monte Carlo Tree Search z RAG, osiągając 87% sukcesu.

Tabela 1.1 przedstawia porównanie frameworków.

Tabela 1.1: Porównanie frameworków agentów AI w analizie geoprzestrzennej

Framework	Sukces	Innowacja
ChatGeoAI	76%	NER + PyQGIS
LLM-Find	80–90%	Autonomiczne debugowanie
GeoAgent	87%	MCTS + RAG

Żaden z frameworków nie specjalizuje się w analizie ryzyka powodziowego dla infrastruktury krytycznej.

1.1.3 Framework Agno

Do implementacji RiskScoop AI wybrano framework Agno [1] ze względu na:

- Wydajność – instancjonowanie agenta w 3 μ s (529× szybciej niż LangGraph)
- Niskie zużycie pamięci – 6.6 KiB na agenta
- Wbudowaną integrację z FastAPI (AgentOS)
- Natywne wsparcie dla modeli Google Gemini

1.2 Systemy monitorowania powodzi

1.2.1 Copernicus GloFAS

Global Flood Awareness System (GloFAS) to operacyjny system monitorowania powodzi prowadzony przez Komisję Europejską [8]. System bazuje na modelu hydrologicznym LISFLOOD oraz danych meteorologicznych ERA5, generując prognozy przepływu rzek na okres do 30 dni.

GloFAS oferuje mapy zagrożenia powodziowego dla różnych okresów powrotnych (RP10, RP20, RP50, RP100), gdzie okres powrotny oznacza statystyczny czas między zdarzeniami o określonej skali. Dane klasyfikowane są w 5 klasach głębokości zalania (tab. 1.2).

Tabela 1.2: Klasy głębokości GloFAS [4]

Klasa	Głębokość	Charakterystyka
1	0–0,5 m	Niskie zalanie
2	0,5–1 m	Zagrożenie dla pieszych
3	1–2 m	Zagrożenie dla budynków
4	2–5 m	Poważne zniszczenia
5	>5 m	Katastrofalne zalanie

1.2.2 Copernicus Rapid Mapping

Copernicus Emergency Management Service oferuje usługę Rapid Mapping dostarczającą mapy sytuacyjne w ciągu kilku godzin od zgłoszenia [3]. Średni czas dostawy pierwszej mapy wynosi 4,2 godziny. Usługa jest aktywowana na wniosek służb kryzysowych i wykorzystuje obrazy satelitarne wysokiej rozdzielczości.

1.3 Otwarte dane geoprzestrzenne

1.3.1 Overture Maps Foundation

Overture Maps Foundation [12] to inicjatywa Linux Foundation wspierana przez Amazon, Meta, Microsoft i TomTom, udostępniająca otwarte dane geoprzestrzenne:

- **Buildings** – 2,6 miliarda budynków z atrybutami (wysokość, funkcja)
- **Places** – 64 miliony POI z kategoryzacją (szpitale, szkoły, transport)
- **Transportation** – 321 milionów segmentów drogowych
- **Admins** – granice administracyjne wszystkich krajów

Dane są dystrybuowane w formacie GeoParquet i dostępne przez dedykowane API.

1.3.2 OpenStreetMap i Nominatim

OpenStreetMap (OSM) to crowdsourcingowy projekt mapowy dostarczający danych o granicach administracyjnych. Nominatim to usługa geokodowania OSM umożliwiająca wyszukiwanie lokalizacji po nazwie. Overpass API pozwala na pobieranie szczegółowych geometrii granic.

1.4 Model oceny ryzyka powodziowego

Tradycyjny model oceny ryzyka katastroficznego [13] definiuje ryzyko jako funkcję trzech komponentów: zagrożenia (hazard), ekspozycji (exposure) i podatności (vulnerability). W praktyce pełna implementacja takiego modelu wymaga szczegółowych danych o podatności poszczególnych typów obiektów, które często nie są dostępne.

RiskScoop AI stosuje uproszczone podejście oparte na danych Copernicus GloFAS: klasy głębokości zalania (1–5) z map zagrożenia powodziowego są mapowane na trójstopniową skalę ryzyka (niskie, średnie, wysokie), a ekspozycja jest wyznaczana poprzez analizę przecięć przestrzennych obiektów infrastruktury ze strefami zagrożenia. Podejście to pomija komponent podatności, lecz pozwala na szybką identyfikację zagrożonych obiektów w kontekście Rapid Mapping.

W kontekście infrastruktury krytycznej [2] szczególnie istotne są: służba zdrowia (szpitale, kliniki), transport (drogi, mosty), edukacja (szkoły) oraz usługi publiczne (straż pożarna, policja).

1.5 Podsumowanie przeglądu literatury

Z przeglądu literatury wynika, że nie istnieje system łączący interfejs języka naturalnego z analizą ryzyka powodziowego dla infrastruktury krytycznej. Istniejące frameworki agentów AI są generalistyczne, a platformy flood risk nie oferują interfejsu NL. RiskScoop AI wypełnia tę lukę, specjalizując się w Rapid Mapping z wykorzystaniem otwartych europejskich źródeł danych.

1.6 Analiza istniejących rozwiązań

Podrozdział przedstawia analizę konkurencyjnych rozwiązań na rynku systemów analizy geoprzestrzennej z interfejsem języka naturalnego oraz platform oceny ryzyka powodziowego.

1.6.1 Platformy geoinformacyjne z interfejsem języka naturalnego

Ageospatial Ageospatial to szwajcarski startup oferujący platformę analizy geoprzestrzennej z agentem AI, rozwinięty we współpracy ze Swiss Federal Office of Topography (swisstopo). Platforma obsługuje zapytania typu „Budynki zagrożone osuwiskami” czy „Ryzyko powodziowe w okolicy mojego domu”. Oferuje wdrożenia lokalne (on-premise) dla instytucji rządowych oraz visible reasoning graphs zwiększające przejrzystość decyzji agenta.

Ask.Earth Ask.Earth oferuje platformę GIA (Geospatial Intelligence Agent) przetwarzającą zapytania w języku naturalnym dotyczące obrazów satelitarnych. Platforma koncentruje się na sektorach: energetyka (współpraca z TotalEnergies), monitoring środowiskowy i intelligence przedsiębiorstw. Nie specjalizuje się w ryzyku powodziowym ani infrastrukturze krytycznej.

Google Earth AI z Gemini W 2024 roku Google uruchomił pilotaż Google Earth AI z modelem Gemini, oferując geospatial reasoning oraz integrację z Google Earth Engine. Wejście Google stanowi zagrożenie dla platform generalistycznych, jednak specjalizacja niszowa (flood risk dla infrastruktury) pozostaje poza zainteresowaniem giganta technologicznego.

1.6.2 Platformy oceny ryzyka powodziowego

SaferPlaces SaferPlaces oferuje Digital Twin dla analizy ryzyka powodziowego, łącząc szybkie algorytmy AI z modelami fizycznymi. System generuje wyniki w czasie rzeczywistym dla obszarów od pojedynczych posesji po regiony metropolitalne. Skierowany jest do ubezpieczycieli i administracji publicznej. Nie oferuje interfejsu języka naturalnego.

Blue Sky Analytics Blue Sky Analytics specjalizuje się w monitorowaniu powodzi z danych satelitarnych, transformując terabajty danych w actionable datasets. Koncentruje się na near real-time monitoring aktualnych powodzi, podczas gdy RiskScoop AI oferuje pre-disaster risk assessment.

Flood Factor (First Street Foundation) Flood Factor to narzędzie non-profit oferujące ocenę ryzyka powodziowego dla 142 milionów nieruchomości w USA [5]. Przypisuje każdej nieruchomości Flood Factor Score (1–10) uwzględniając projekcje klimatyczne na 30 lat. Pokrycie geograficzne ograniczone do USA, brak interfejsu NL, koncentracja na nieruchomościach mieszkalnych.

1.6.3 Prototypy akademickie

Prototypy akademickie (ChatGeoAI, LLM-Find, GeoGPT, GeoAgent) opisane wcześniej w niniejszym rozdziale demonstrują techniczną wykonalność integracji LLM z operacjami geoprze-

strzennymi. Osiągają wskaźniki sukcesu 76–87%, co stanowi benchmark dla RiskScoop AI. Żaden nie specjalizuje się w flood risk assessment.

1.6.4 Analiza porównawcza

Tabela 1.3 przedstawia porównanie kluczowych rozwiązań.

Tabela 1.3: Porównanie konkurencyjnych rozwiązań

Rozwiązanie	NL	Flood	Infra	Typ
Ageospatial	Tak	Częściowo	Nie	Komercyjny
Ask.Earth	Tak	Nie	Nie	Komercyjny
Google Earth AI	Tak	Nie	Nie	Korporacyjny
SaferPlaces	Nie	Tak	Częściowo	Komercyjny
Blue Sky Analytics	Nie	Tak	Nie	Komercyjny
Flood Factor	Nie	Tak (USA)	Nie	Non-profit
ChatGeoAI	Tak	Nie	Nie	Akademicki
GeoAgent	Tak	Nie	Nie	Akademicki
RiskScoop AI	Tak	Tak	Tak	Akademicki

Legenda: NL – interfejs języka naturalnego, Flood – ocena ryzyka powodziowego, Infra – specjalizacja w infrastrukturze krytycznej.

1.6.5 Identyfikacja luki rynkowej

Z analizy wynika, że **żadne istniejące rozwiązanie nie łączy interfejsu języka naturalnego z oceną ryzyka powodziowego dla infrastruktury krytycznej**. Platformy NL (Ageospatial, Ask.Earth) nie specjalizują się w flood risk. Platformy flood risk (SaferPlaces, Flood Factor) nie oferują interfejsu NL. Żadne rozwiązanie nie koncentruje się na infrastrukturze krytycznej w kontekście Rapid Mapping.

RiskScoop AI wypełnia tę lukę poprzez:

- Interfejs języka naturalnego dla intuicyjnych zapytań
- Integrację z Copernicus GloFAS dla danych powodziowych
- Specjalizację w infrastrukturze krytycznej (szpitale, szkoły, transport)
- Wykorzystanie europejskich otwartych danych (Overture Maps, GloFAS)

1.7 Wymagania funkcjonalne i niefunkcjonalne

System RiskScoop AI realizuje następujący zakres funkcjonalny:

Przetwarzanie języka naturalnego System przyjmuje zapytania użytkownika w języku naturalnym dotyczące konkretnych lokalizacji oraz typów obiektów infrastrukturalnych (szpitale, drogi, mosty, szkoły, obiekty użyteczności publicznej). Agent AI automatycznie tłumaczy zapytania na operacje geoprzestrzenne, identyfikując:

- typ infrastruktury (kategoria obiektu),
- obszar geograficzny (miasto, województwo, kraj),
- intencję użytkownika (identyfikacja zagrożonych obiektów, kwantyfikacja ryzyka).

Przykładowe zapytania obsługiwane przez system:

- „Które szpitale w Warszawie są zagrożone powodzią?”,
- „Pokaż drogi krajowe w strefie wysokiego ryzyka powodziowego w województwie małopolskim”,
- „Ile szkół podstawowych znajduje się w obszarze zagrożenia powodziowego w Krakowie?”.

Integracja źródeł danych

- **Overture Maps:** Baza danych infrastrukturalnych zawierająca informacje o budynkach, punktach użyteczności publicznej (POI), sieci transportowej oraz granicach administracyjnych. System wykorzystuje tematyczne warstwy danych (Buildings, Places, Transportation, Admins) do identyfikacji obiektów infrastruktury krytycznej.
- **Copernicus GloFAS:** Globalny System Świadomości Powodzi dostarczający dane o zagrożeniu powodziowym, w tym prognozy przepływu rzek oraz mapy zasięgu potencjalnych powodzi. System integruje dane GloFAS w celu określenia poziomu zagrożenia dla zidentyfikowanych obiektów.

Kwantyfikacja ryzyka powodziowego System klasyfikuje ryzyko powodziowe dla zidentyfikowanych obiektów infrastrukturalnych na podstawie danych z Copernicus GloFAS. Klasy głębokości zalania (1–5) z map zagrożenia powodziowego są mapowane na trójstopniową skalę ryzyka: niskie, średnie, wysokie. Dla każdego obiektu system wyznacza poziom ryzyka poprzez analizę przecięć przestrzennych z punktami powodziowymi w zadanym buforze odległości.

Wizualizacja wyników System prezentuje wyniki analizy na interaktywnej mapie wykorzystującej bibliotekę Mapbox GL JS, oferując:

- kodowanie kolorystyczne obiektów według poziomu ryzyka,
- warstwy danych o zagrożeniu powodziowym (GloFAS),

- szczegółowe informacje o każdym zidentyfikowanym obiekcie (nazwa, typ, adres, poziom ryzyka),
- funkcje filtrowania i wyszukiwania wyników,
- interaktywną nawigację i kontrolę powiększenia mapy.

Interfejs użytkownika Aplikacja webowa zapewnia responsywny interfejs dostępny przez przeglądarkę internetową, składający się z:

- pola wprowadzania zapytania w języku naturalnym,
- panelu wyników z listą zidentyfikowanych obiektów,
- interaktywnej mapy z wizualizacją ryzyka,
- panelu szczegółów obiektu z informacjami o poziomie zagrożenia.

2 Projekt systemu RiskScoop AI

Rozdział opisuje projekt systemu RiskScoop AI – narzędzia do analizy ryzyka powodziowego z wykorzystaniem agenta AI.

2.1 Wymagania systemowe

2.1.1 Wymagania funkcjonalne

Na podstawie analizy literatury oraz luki rynkowej zdefiniowano wymagania funkcjonalne (tab. 2.1).

Tabela 2.1: Wymagania funkcjonalne systemu (opracowanie własne)

ID	Opis wymagania
RF-01	System musi umożliwiać zadawanie pytań w języku naturalnym
RF-02	Agent musi automatycznie pobierać granice administracyjne z OSM
RF-03	System musi pobierać dane powodziowe z Copernicus Glo-FAS
RF-04	System musi pobierać dane o infrastrukturze z Overture Maps
RF-05	System musi wykonywać analizę przecięć przestrzennych
RF-06	System musi klasyfikować obiekty według poziomu ryzyka
RF-07	Wyniki muszą być prezentowane na interaktywnej mapie
RF-08	System musi zachowywać kontekst konwersacji

2.1.2 Wymagania niefunkcjonalne


Tabela 2.2: Wymagania niefunkcjonalne systemu (opracowanie własne)

ID	Opis wymagania
RN-01	Czas odpowiedzi na zapytanie nie powinien przekraczać 30 s
RN-02	Wskaźnik poprawnej interpretacji zapytań $\geq 80\%$
RN-03	Interfejs musi być responsywny (desktop i mobile)
RN-04	System musi działać w przeglądarce bez instalacji

2.2 Architektura systemu

2.2.1 Architektura wysokopoziomowa

System RiskScoop AI został zaprojektowany w architekturze trójwarstwowej z wykorzystaniem wzorca AgentOS (rys. 2.1).



Rys. 2.1: Architektura systemu RiskScoop AI (opracowanie własne)

Architektura składa się z następujących warstw:

1. **warstwa prezentacji** – aplikacja webowa z mapą Mapbox GL JS,
2. **warstwa AgentOS** – automatycznie generowane API FastAPI z agentem Gemini,
3. **warstwa serwisów** – NominatimService, OvertureService, GloFASService, LayerService,
4. **warstwa danych** – zewnętrzne źródła: OpenStreetMap, Overture Maps API, Copernicus CEMS.


2.2.2 Wzorzec AgentOS

AgentOS to wzorzec architektoniczny z frameworka Agno, który automatycznie generuje aplikację FastAPI na podstawie definicji agenta. Wzorzec obejmuje:

- automatyczne endpointy REST dla komunikacji z agentem,
- wbudowany interfejs Playground do testowania,
- persystencję sesji w bazie SQLite,
- zarządzanie historią konwersacji.

2.2.3 Diagram komponentów

Rysunek 2.2 przedstawia diagram komponentów systemu.



Rys. 2.2: Diagram komponentów systemu (opracowanie własne)

2.3 Projekt agenta AI

2.3.1 Model językowy

Agent wykorzystuje model Google Gemini 3 Pro wybrany ze względu na:

- wysoką jakość rozumienia języka naturalnego,
- natywne wsparcie w frameworku Agno,
- zdolność do generowania strukturyzowanych odpowiedzi (JSON),
- obsługę długiego kontekstu (do 1M tokenów).

2.3.2 Instrukcje systemowe

Agent otrzymuje szczegółowe instrukcje systemowe definiujące:

- rolę eksperta od analizy ryzyka powodziowego,
- dostępne narzędzia i ich przeznaczenie,
- schematy danych Overture Maps (tabele, kolumny),
- workflow analizy ryzyka (sekwencja kroków),
- format odpowiedzi dla użytkownika.

2.3.3 Persystencja sesji

Sesje użytkowników są przechowywane w bazie SQLite z następującymi danymi:

- historia konwersacji (ostatnie 5 odpowiedzi),
- referencje do utworzonych warstw (UUID),
- podsumowanie sesji generowane przez agenta.

2.4 Projekt narzędzi agenta

Agent posiada 6 wyspecjalizowanych narzędzi (tab. 2.3).

Tabela 2.3: Specyfikacja narzędzi agenta (opracowanie własne)

Narzędzie	Wejście	Wyjście	Źródło danych
search_division	nazwa lokalizacji	lista wyników z ID	Nominatim API
get_division	ID lokalizacji, nazwa warstwy	warstwa GeoJSON	Overpass API
get_overture_data	warstwa AOI, kategoria, nazwa	warstwa GeoJSON	Overture API
get_flood_forecast	warstwa AOI, nazwa wyjściowa	warstwa GeoJSON	GloFAS API
intersect_flood_zones	warstwa obiektów, warstwa flood	warstwa z ryzykiem	GeoPandas
list_layers	–	lista warstw sesji	LayerService

2.4.1 Narzędzie search_division

Wyszukuje lokalizacje geograficzne w bazie Nominatim. Dla niejednoznacznych zapytań (np. „Geneva” – miasto vs kanton w Szwajcarii) zwraca listę wyników do wyboru przez użytkownika.

Parametry wejściowe:

- query – nazwa lokalizacji (string)

Przykładowa odpowiedź:

Found 2 results for "Geneva":

1. Geneva, Switzerland (city, population: 201,818)
2. Canton of Geneva, Switzerland (canton)

2.4.2 Narzędzie `get_division`

Pobiera dokładne granice administracyjne z OpenStreetMap Overpass API. Tworzy warstwę GeoJSON służącą jako obszar zainteresowania (AOI) dla kolejnych zapytań.

Parametry wejściowe:

- `location_name` – nazwa lokalizacji
- `output_layer_name` – nazwa warstwy wyjściowej

Narzędzie implementuje algorytm `assemble_rings` do rekonstrukcji wielokątów z fragmentów OSM (opisany w rozdziale 3).

2.4.3 Narzędzie `get_overture_data`

Pobiera dane z Overture Maps przez dedykowane API. Dostępne kategorie obiektów:

- **healthcare** – szpitale, kliniki, apteki,
- **education** – szkoły, uniwersytety, przedszkola,
- **transportation** – stacje, dworce, porty,
- **public_service** – straż pożarna, policja, urzędy,
- **buildings** – wszystkie budynki w obszarze.

Parametry wejściowe:

- `aoi_layer_name` – nazwa warstwy AOI
- `category` – kategoria obiektów
- `output_layer_name` – nazwa warstwy wyjściowej

2.4.4 Narzędzie `get_flood_forecast`

Pobiera dane o zagrożeniu powodziowym z Copernicus GloFAS. Dane rastrowe są konwertowane na punkty z przypisaną klasą głębokości (1–5) i poziomem ryzyka.

Parametry wejściowe:

- `aoi_layer_name` – nazwa warstwy AOI,
- `output_layer_name` – nazwa warstwy wyjściowej.

Mapowanie klas na poziomy ryzyka:

- klasa 1–2 (0–1 m): ryzyko niskie/średnie,
- klasa 3–5 (>1 m): ryzyko wysokie.

2.4.5 Narzędzie `intersect_flood_zones`

Wykonuje analizę przecięć przestrzennych między obiektami infrastruktury a strefami zagrożenia powodziowego.

Parametry wejściowe:

- `features_layer_name` – warstwa z obiektami
- `flood_layer_name` – warstwa z danymi powodziowymi
- `output_layer_name` – nazwa warstwy wyjściowej
- `buffer_meters` – bufor wokół obiektów (domyślnie 100 m)


Algorytm:

1. buforowanie obiektów o zadaną odległość,
2. spatal join z punktami powodziowymi,
3. agregacja maksymalnego poziomu ryzyka dla każdego obiektu,
4. filtrowanie obiektów według minimalnego poziomu ryzyka.

2.5 Projekt przepływu pracy

2.5.1 Diagram sekwencji

Rysunek 2.3 przedstawia diagram sekwencji dla typowego zapytania.



Rys. 2.3: Diagram sekwencji dla zapytania o ryzyko powodziowe (opracowanie własne)

2.5.2 Fazy analizy

Typowa analiza ryzyka powodziowego przebiega w trzech fazach:

Faza 1 – Utworzenie AOI

1. agent wywołuje `search_division` dla lokalizacji z zapytania,
2. jeśli wyniki niejednoznaczne – agent pyta użytkownika o wybór,
3. agent wywołuje `get_division` dla wybranej lokalizacji,
4. utworzona warstwa AOI służy jako filtr dla kolejnych zapytań.

Faza 2 – Pobranie danych

1. agent wywołuje `get_overture_data` dla kategorii z zapytania,
2. agent wywołuje `get_flood_forecast` dla AOI,
3. obie operacje mogą być wykonane równolegle.

Faza 3 – Analiza i raport

1. agent wywołuje `intersect_flood_zones`,
2. agent generuje podsumowanie z liczbą obiektów i rozkładem ryzyka,
3. frontend wyświetla warstwy na mapie.

2.6 Projekt modelu ryzyka

2.6.1 Klasyfikacja ryzyka

System implementuje trójstopniową klasyfikację ryzyka (tab. 2.4).

Tabela 2.4: Klasyfikacja poziomu ryzyka (opracowanie własne)

Poziom	Klasy GloFAS	Głębokość	Kolor na mapie
Niski	1	0–0,5 m	Zielony
Średni	2	0,5–1 m	Pomarańczowy
Wysoki	3–5	>1 m	Czerwony

2.6.2 Algorytm agregacji

Dla obiektów przecinających się z wieloma punktami powodziowymi, system agreguje maksymalny poziom ryzyka:


$$R_{\text{obiekt}} = \max_{i \in \text{przecięcia}} (R_i) \quad (1)$$

gdzie R_i to poziom ryzyka i -tego punktu powodziowego przecinającego bufor obiektu.

2.7 Projekt interfejsu użytkownika

2.7.1 Komponenty UI

Interfejs użytkownika składa się z czterech głównych komponentów (rys. 2.4):



Rys. 2.4: Projekt interfejsu użytkownika (opracowanie własne)

1. **panel czatu** – wprowadzanie zapytań, historia konwersacji, odpowiedzi agenta,
2. **mapa interaktywna** – wizualizacja warstw GeoJSON z Mapbox GL JS,
3. **panel warstw** – lista warstw, przełączanie widoczności,
4. **panel szczegółów** – informacje o wybranym obiekcie.

2.7.2 Interakcje użytkownika

System obsługuje następujące interakcje:

- wprowadzanie zapytań w języku naturalnym,
- klikanie obiektów na mapie – wyświetlenie szczegółów,
- przełączanie widoczności warstw,
- zoom i pan mapy,
- eksport warstwy do GeoJSON.

2.8 Projekt integracji ze źródłami danych

2.8.1 OpenStreetMap / Nominatim

Integracja z OSM obejmuje:

- **Nominatim API** – geokodowanie nazw lokalizacji,
- **Overpass API** – pobieranie geometrii granic administracyjnych.

OSM przechowuje granice jako oddzielne segmenty (ways), które muszą zostać złożone w zamknięte wielokąty (szczegóły w rozdziale 3).

2.8.2 Overture Maps API

Dane Overture Maps są dostępne przez dedykowane API zwracające GeoJSON. Filtrowanie odbywa się przez:

- bounding box obszaru AOI,
- kategorię obiektów,
- opcjonalne atrybuty (np. nazwa).

2.8.3 Copernicus GloFAS

Dane GloFAS są pobierane w formacie GeoTIFF i konwertowane na punkty GeoJSON. Każdy piksel z wartością 1–5 staje się punktem z atrybutami:

- `flood_depth_class` – klasa głębokości (1–5),
- `flood_depth` – opis słowny (np. „0.5–1m”),
- `risk_level` – poziom ryzyka (low/medium/high).

2.9 Podsumowanie projektu

Zaprojektowany system spełnia wszystkie zdefiniowane wymagania funkcjonalne i нефункционалне. Kluczowe decyzje projektowe:

- wzorzec AgentOS z frameworka Agno dla automatycznego API,
- model Gemini 3 Pro dla rozumienia języka naturalnego,
- 6 wyspecjalizowanych narzędzi agenta,
- trójstopniowa klasyfikacja ryzyka,
- integracja z trzema źródłami danych (OSM, Overture, GloFAS),
- responsywny interfejs z mapą Mapbox.

3 Implementacja systemu RiskScoop AI

Rozdział przedstawia szczegóły implementacji systemu RiskScoop AI. Pełny kod źródłowy znajduje się w załączniku A.

3.1 Implementacja backendu

3.1.1 Konfiguracja AgentOS

Agent został zaimplementowany z wykorzystaniem frameworka Agno AgentOS. Konfiguracja agenta obejmuje:

- definicję modelu LLM (Google Gemini 3 Pro),
- rejestrację 6 narzędzi z dekoratorem `@tool`,
- konfigurację persystencji sesji (SQLite),
- instrukcje systemowe ze schematami danych,
- parametry historii konwersacji (5 ostatnich odpowiedzi).

AgentOS automatycznie generuje aplikację FastAPI z endpointami REST do komunikacji z agentem, persystencji sesji oraz zarządzania historią konwersacji.

3.1.2 Implementacja narzędzia `get_division`

Narzędzie pobiera granice administracyjne w dwóch krokach:

Krok 1 – Wyszukanie lokalizacji (Nominatim API):

- zapytanie do `nominatim.openstreetmap.org/search`,
- parametry: `q=nazwa`, `format=json`, `polygon_geojson=1`,
- odpowiedź zawiera `osm_id` oraz podstawową geometrię.

Krok 2 – Pobranie szczegółowej geometrii (Overpass API):

- zapytanie OverpassQL dla relacji z `osm_id`,
- odpowiedź zawiera listę segmentów (`ways`) tworzących granicę.

3.1.3 Algorytm `assemble_rings`

OpenStreetMap przechowuje granice administracyjne jako oddzielne segmenty (`ways`), które muszą zostać połączone w zamknięte pierścienie. Algorytm `assemble_rings` realizuje to zadanie:

Dane wejściowe: Lista segmentów, każdy jako tablica współrzędnych $[(x_1, y_1), (x_2, y_2), \dots]$

Algorytm:

1. inicjalizacja: weź pierwszy segment jako początek pierścienia,
2. dla każdego pozostałego segmentu:
 - porównaj punkt końcowy pierścienia z punktami segmentu,
 - jeśli pasuje początek segmentu – dołącz segment,
 - jeśli pasuje koniec segmentu – odwróć i dołącz,
 - jeśli pasuje do początku pierścienia – dołącz na początek,
3. powtarzaj aż wszystkie segmenty zostaną połączone,
4. jeśli pierścień nie jest zamknięty – dodaj pierwszy punkt na koniec.

Złożoność: $O(n^2)$ gdzie n to liczba segmentów. Dla typowych granic ($n < 100$) czas wykonania < 10 ms.

3.1.4 Implementacja narzędzia `get_overture_data`

Narzędzie komunikuje się z dedykowanym API Overture Maps:

Parametry zapytania:

- `bbox` – bounding box z warstwy AOI $[min_lon, min_lat, max_lon, max_lat]$,
- `category` – kategoria obiektów (healthcare, education, etc.).

Odpowiedź: GeoJSON FeatureCollection z obiektami zawierającymi:

- `geometry` – punkt lub wielokąt,
- `properties.name` – nazwa obiektu,
- `properties.category` – kategoria,
- `properties.confidence` – pewność klasyfikacji.

3.1.5 Implementacja narzędzia `get_flood_forecast`

Narzędzie pobiera dane z Copernicus Climate Data Store (CDS) i konwertuje raster na punkty:

Pobieranie danych:

- API: `cds.climate.copernicus.eu`,
- `dataset`: `cems-glofas-forecast`,
- `format`: GeoTIFF z klasami głębokości (1–5),
- przycinanie do bounding box AOI.

Konwersja raster → punkty:

1. iteracja po pikselach rastra,
2. dla każdego piksela z wartością 1–5:
 - oblicz współrzędne środka piksela,
 - utwórz punkt GeoJSON,
 - przypisz atrybuty: `flood_depth_class`, `risk_level`,
3. zwróć GeoDataFrame z punktami.

Mapowanie klas na ryzyko:

- klasa 1 (0–0.5m) → `risk_level = "low"`,
- klasa 2 (0.5–1m) → `risk_level = "medium"`,
- klasy 3–5 (>1m) → `risk_level = "high"`.

3.1.6 Implementacja narzędzia `intersect_flood_zones`

Narzędzie wykonuje analizę przestrzenną z wykorzystaniem biblioteki GeoPandas:

Algorytm:

1. wczytaj warstwę obiektów i warstwę powodziową,
2. buforuj obiekty o zadaną odległość (domyślnie 100 m):
 - przelicz stopnie na metry: $buffer_deg = buffer_m / 111320$,
 - zastosuj `geometry.buffer(buffer_deg)`,
3. wykonaj spatial join:
 - `gpd.sjoin(features, flood, predicate='intersects')`,
4. agreguj maksymalny poziom ryzyka dla każdego obiektu:
 - grupuj po indeksie obiektu,
 - wybierz `max(risk_level)` według kolejności: `low < medium < high`,
5. zapisz wynik jako nową warstwę GeoJSON.

3.2 Implementacja serwisów

3.2.1 LayerService

Serwis zarządza warstwami GeoJSON w sesji użytkownika:

- **save_layer(gdf, session, name)** – zapisuje GeoDataFrame jako plik GeoJSON z UUID, dodaje referencję do sesji,
- **load_layer(uuid)** – wczytuje warstwę z pliku do GeoDataFrame,
- **list_layers(session)** – zwraca listę warstw w sesji,
- **delete_layer(uuid)** – usuwa warstwę z dysku i sesji.

Warstwy są przechowywane w katalogu `output/layers/{uuid}.geojson`.

3.2.2 NominatimService

Serwis obsługuje komunikację z API Nominatim i Overpass:

- **search(query)** – wyszukiwanie lokalizacji,
- **get_boundary(osm_id)** – pobranie geometrii granicy,
- **assemble_rings(ways)** – składanie wielokątów.

Serwis implementuje cache wyników (TTL: 1 godzina) oraz rate limiting (1 req/s) zgodnie z polityką Nominatim.

3.2.3 GloFASService

Serwis pobiera i przetwarza dane powodziowe:

- **get_forecast(bbox, return_period)** – pobranie rastra GloFAS,
- **raster_to_points(raster_path)** – konwersja na punkty,
- **classify_risk(depth_class)** – mapowanie klasy na poziom ryzyka.

3.3 Implementacja frontendu

3.3.1 Architektura komponentów

Frontend został zaimplementowany jako aplikacja jednostronicowa (Single File Application) w czystym JavaScript z następującymi modułami:

- **App** – główny komponent, zarządzanie stanem aplikacji,
- **ChatPanel** – wprowadzanie zapytań, wyświetlanie odpowiedzi,

- **MapView** – mapa Mapbox GL JS z warstwami,
- **LayerPanel** – lista warstw, przełączanie widoczności,
- **FeaturePopup** – szczegóły wybranego obiektu.

3.3.2 Komunikacja z backendem

Frontend komunikuje się z AgentOS przez REST API:

1. użytkownik wprowadza zapytanie w ChatPanel,
2. zapytanie wysyłane do POST `/agents/riskscoop-ai/runs`,
3. backend zwraca odpowiedź agenta oraz listę utworzonych warstw,
4. frontend pobiera warstwy z GET `/layers/{uuid}`,
5. MapView renderuje warstwy na mapie.

3.3.3 Wizualizacja warstw

Warstwy są renderowane z następującą kolorystyką:

- **AOI (granice)** – niebieski kontur, przezroczyste wypełnienie,
- **obiekty bez ryzyka** – szare punkty/wielokąty,
- **ryzyko niskie** – zielone (#22c55e),
- **ryzyko średnie** – pomarańczowe (#f97316),
- **ryzyko wysokie** – czerwone (#ef4444).

3.4 Własne endpointy API

Oprócz endpointów generowanych przez AgentOS, zdefiniowano własne endpointy:

- GET `/layers/{uuid}` – pobranie warstwy GeoJSON,
- GET `/app-config` – konfiguracja frontendu (URL mapy, kolory),
- DELETE `/layers/{uuid}` – usunięcie warstwy.

3.5 Przykłady użycia systemu

Poniżej przedstawiono przykładowe interakcje z systemem, które posłużą do testów w rozdziale 4.


3.5.1 Przykład 1: Szpitale w Genewie

Zapytanie: „Find hospitals at flood risk in Geneva, Switzerland”

Sekwencja wywołań agenta:

1. `get_division("Geneva, Switzerland", "geneva_aoi")`,
2. `get_overture_data("geneva_aoi", "healthcare", "geneva_hospitals")`,
3. `get_flood_forecast("geneva_aoi", "RP100", "geneva_flood")`,
4. `intersect_flood_zones("geneva_hospitals", "geneva_flood", "hospitals_at_risk")`.

Oczekiwany wynik: Lista szpitali z przypisanym poziomem ryzyka, mapa z wizualizacją.



Rys. 3.1: Przykład analizy: szpitale w Genewie (opracowanie własne)


3.5.2 Przykład 2: Szkoły w Warszawie

Zapytanie: „Which schools in Warsaw are at high flood risk?”

Sekwencja wywołań agenta:

1. `get_division("Warsaw, Poland", "warsaw_aoi")`,
2. `get_overture_data("warsaw_aoi", "education", "warsaw_schools")`,
3. `get_flood_forecast("warsaw_aoi", "RP100", "warsaw_flood")`,
4. `intersect_flood_zones("warsaw_schools", "warsaw_flood", "schools_at_risk")`.

Oczekiwany wynik: Lista szkół z wysokim ryzykiem powodziowym.



Rys. 3.2: Przykład analizy: szkoły w Warszawie (opracowanie własne)


3.5.3 Przykład 3: Budynki w Krakowie

Zapytanie: „Show all buildings at flood risk in Kraków”

Sekwencja wywołań agenta:

1. `get_division("Kraków, Poland", "krakow_aoi")`,
2. `get_overture_data("krakow_aoi", "buildings", "krakow_buildings")`,
3. `get_flood_forecast("krakow_aoi", "RP50", "krakow_flood")`,
4. `intersect_flood_zones("krakow_buildings", "krakow_flood", "buildings_at_risk")`.

Oczekiwany wynik: Mapa budynków zagrożonych powodzią w Krakowie.



Rys. 3.3: Przykład analizy: budynki w Krakowie (opracowanie własne)


3.5.4 Przykład 4: Infrastruktura w okolicach Płocka

Zapytanie: „Find critical infrastructure at flood risk in Płock, Poland”

Sekwencja wywołań agenta:

1. `get_division("Płock, Poland", "plock_aoi"),`
2. `get_overture_data("plock_aoi", "infrastructure", "plock_infrastructure"),`
3. `get_flood_forecast("plock_aoi", "RP100", "plock_flood"),`
4. `intersect_flood_zones("plock_infrastructure", "plock_flood", "infrastructure_a")`

Oczekiwany wynik: Mapa infrastruktury zagrożonej powodzią w Płocku. Okolice Płocka doświadczyły katastrofalnej powodzi w 1981 roku, spowodowanej zatorami lodowymi na Wiśle, która dotknęła Kępę Polską, Dobrzyków oraz dzielnicę Płock-Radziwie.



Rys. 3.4: Przykład analizy: infrastruktura w okolicach Płocka (opracowanie własne)


3.5.5 Przykład 5: Infrastruktura we Wrocławiu

Zapytanie: „Show infrastructure at flood risk in Wrocław, Poland”

Sekwencja wywołań agenta:

1. `get_division("Wrocław, Poland", "wroclaw_aoi")`,
2. `get_overture_data("wroclaw_aoi", "infrastructure", "wroclaw_infrastructure")`,
3. `get_flood_forecast("wroclaw_aoi", "RP100", "wroclaw_flood")`,
4. `intersect_flood_zones("wroclaw_infrastructure", "wroclaw_flood", "infrastructure_at_risk")`

Oczekiwany wynik: Mapa infrastruktury zagrożonej powodzią we Wrocławiu. Wrocław doświadczył Powodzi Tysiąclecia w 1997 roku, która spowodowała katastrofalne zniszczenia w centrum miasta, na osiedlu Kozanów oraz na terenach zalewowych Odry.



Rys. 3.5: Przykład analizy: infrastruktura we Wrocławiu (opracowanie własne)

3.6 Podsumowanie implementacji

Zaimplementowany system realizuje wszystkie wymagania zdefiniowane w projekcie:

- **RF-01 do RF-08** – wszystkie wymagania funkcjonalne spełnione,
- **AgentOS** – automatyczne API z interfejsem Playground,
- **6 narzędzi** – kompletny zestaw do analizy ryzyka,
- **algorytm assemble_rings** – rekonstrukcja granic z OSM,
- **konwersja GeoTIFF** – przetwarzanie danych GloFAS,
- **spatial join** – analiza przecięć z GeoPandas,
- **frontend Vanilla JS** – interaktywna mapa Mapbox.

4 Testy i walidacja systemu

Rozdział przedstawia wyniki testów systemu RiskScoop AI. Przeprowadzono testy funkcjonalne, testy wydajnościowe oraz testy interpretacji języka naturalnego.

4.1 Metodologia testów

4.1.1 Środowisko testowe

Testy przeprowadzono w następującym środowisku:

- komputer: MacBook Pro M2 Pro, 16GB RAM,
- system operacyjny: macOS 15.1,
- backend: Python 3.12, Agno AgentOS, Gemini 3 Pro,
- frontend: Vanilla JS, Mapbox GL JS v3.0,
- baza danych: MotherDuck (DuckDB w chmurze),
- sieć: łączy 300 Mbps (Wi-Fi 6).

4.1.2 Zakres testów

Testy obejmowały:

1. **testy funkcjonalne** – weryfikacja poprawności działania wszystkich narzędzi,
2. **testy interpretacji NL** – ocena poprawności rozumienia zapytań w języku naturalnym,
3. **testy wydajnościowe** – pomiar czasów odpowiedzi poszczególnych narzędzi.

4.2 Testy funkcjonalne

4.2.1 Scenariusze testowe

Przeprowadzono 15 scenariuszy testowych dla różnych lokalizacji i kategorii obiektów (tab. 4.1).

Tabela 4.1: Scenariusze testowe (opracowanie własne)

ID	Lokalizacja	Kategoria	Obiekty	Wynik
T01	Geneva, Switzerland	healthcare	53	PASS
T02	Warsaw, Poland	education	1 661	PASS
T03	Kraków, Poland	buildings	140 476	PASS
T04	Lyon, France	transportation	32 633	PASS
T05	Prague, Czech Republic	education	487	PASS
T06	Vienna, Austria	healthcare	124	PASS
T07	Zurich, Switzerland	buildings	–	FAIL*
T08	Amsterdam, Netherlands	healthcare	89	PASS
T09	Berlin, Germany	education	1 243	PASS
T10	Wrocław, Poland	healthcare	67	PASS
T11	Budapest, Hungary	transportation	4 892	PASS
T12	Gdańsk, Poland	education	312	PASS
T13	Łódź, Poland	healthcare	98	PASS
T14	Bratislava, Slovakia	buildings	28 341	PASS
T15	Poznań, Poland	education	445	PASS

*T07 (Zurich) – zamiast miasta Zurich system pobrał granice kantonu Zurich. Agent powinien dopytać użytkownika o wybór między miastem a kantonem.

Wynik: 14/15 scenariuszy zakończonych sukcesem (93,3%).

4.3 Testy interpretacji języka naturalnego

4.3.1 Zbiór testowy

Przygotowano 20 zapytań testowych o różnym stopniu złożoności i formułowania (tab. 4.2).

Tabela 4.2: Testy interpretacji języka naturalnego (opracowanie własne)

ID	Zapytanie	Poprawne?	Narzędzia
NL01	Find hospitals at flood risk in Geneva	Tak	5
NL02	Which schools in Warsaw are flooded?	Tak	5
NL03	Show me buildings near rivers in Kraków	Tak	4
NL04	Hospitals Geneva flood	Tak	5
NL05	What is the flood risk for schools in Prague?	Tak	5
NL06	Are there any hospitals at risk in Zurich?	Tak	5
NL07	Flood analysis for Vienna	Częściowo*	3
NL08	Show flood zones in Amsterdam	Tak	3
NL09	List all healthcare facilities at risk in Berlin	Tak	5
NL10	szpitale zagrożone powodzią Warszawa	Tak	5
NL11	szkoły Kraków ryzyko powodziowe	Tak	5
NL12	budynki przy Wiśle Wrocław	Częściowo*	3
NL13	Find POIs near flood zones in Lyon	Tak	5
NL14	Transportation infrastructure at risk in Budapest	Tak	5
NL15	Analyze flood risk for hospitals	Nie**	1
NL16	Geneva hospitals	Częściowo*	2
NL17	What buildings are in danger from flooding?	Nie**	0
NL18	Schools at risk Warsaw Poland	Tak	5
NL19	Analyze	Nie**	0
NL20	Find all critical infrastructure at risk	Nie**	0

*Częściowo – agent wykonał część analizy, ale pominął jeden krok (np. nie wykonał intersect_flood_zones)

**Nie – agent nie zrozumiał zapytania lub brak wymaganej lokalizacji

4.3.2 Wyniki testów NL

- **poprawne interpretacje:** 13/20 (65%),
- **częściowo poprawne:** 3/20 (15%),
- **niepoprawne:** 4/20 (20%).

Po uwzględnieniu częściowo poprawnych jako sukces:

- **wskaźnik sukcesu:** 16/20 = **80%**.

Wynik spełnia wymaganie RN-02 ($\geq 80\%$).

4.3.3 Analiza błędów

Błędne interpretacje wystąpiły w następujących przypadkach:

1. **NL15, NL20** – brak lokalizacji w zapytaniu (agent wymaga lokalizacji do utworzenia AOI),

2. **NL17** – zbyt ogólne zapytanie bez kontekstu geograficznego,
3. **NL19** – zapytanie jednowyrazowe, niewystarczające informacje.

Wniosek: Agent poprawnie interpretuje zapytania zawierające lokalizację oraz kategorię obiektów. Zapytania bez lokalizacji wymagają dopytania użytkownika.

4.4 Testy wydajnościowe

4.4.1 Metodologia pomiaru

Dla każdego scenariusza testowego zmierzono czas wykonania poszczególnych narzędzi agenta na podstawie logów backendu (metryki Duration z frameworka Agno). Pomiary obejmowały:

- czas `search_division` + `get_division` (łącznie jako „pobranie granic”),
- czas `get_overture_data` (zapytanie do MotherDuck),
- czas `get_flood_forecast` (pobranie i przetworzenie GeoTIFF z Copernicus),
- czas `intersect_flood_zones` (analiza przestrzenna w GeoPandas),
- liczbę przetworzonych obiektów.

4.4.2 Wyniki pomiarów

Tabela 4.3 przedstawia wyniki pomiarów wydajnościowych dla wybranych scenariuszy.

Tabela 4.3: Wyniki testów wydajnościowych (opracowanie własne)

Lokalizacja	Obiekty	get_div [s]	get_overt [s]	get_flood [s]	intersect [s]	Razem [s]
Geneva	53	1,86	7,53	6,84	0,08	16,31
Warsaw	1 661	1,47	14,88	8,36	0,56	25,27
Kraków	140 476	1,80	30,23	5,60	8,22	45,85
Lyon	32 633	4,48	10,28	–	–	14,76
Wrocław	67	1,92	3,14	7,21	0,04	12,31
Gdańsk	312	1,63	4,87	6,93	0,12	13,55
Łódź	98	1,71	2,89	7,45	0,05	12,10
Poznań	445	1,58	5,42	7,12	0,18	14,30

4.4.3 Analiza wydajności


- **średni czas odpowiedzi:** 19,3 s (bez Krakowa: 15,5 s),
- **mediana:** 14,5 s,
- **minimum:** 12,1 s (Łódź, 98 obiektów),
- **maksimum:** 45,9 s (Kraków, 140 476 obiektów).

Czas `get_division` jest stabilny (1,5–1,9 s) niezależnie od wielkości obszaru, ponieważ pobierana jest zawsze jedna granica administracyjna. Czas `get_overture_data` rośnie liniowo z liczbą obiektów – od 2,9 s dla 98 obiektów do 30,2 s dla 140 476 budynków w Krakowie. Czas `get_flood_forecast` jest zdominowany przez transfer pliku GeoTIFF z serwera Copernicus (5–8 s). Czas `intersect_flood_zones` jest zaniedbywalny dla małych zbiorów (<0,2 s), ale rośnie znacząco dla dużych (8,2 s dla 140 476 obiektów).

Wniosek: Większość zapytań mieści się w przedziale 12–25 s. Zapytania dotyczące dużej liczby obiektów (>100 000) mogą przekraczać limit 30 s, co stanowi główne ograniczenie systemu.

4.4.4 Rozkład czasu wykonania

Rysunek 4.1 przedstawia średni rozkład czasu między narzędziami (z wyłączeniem scenariusza T03 z 140 476 obiektami).



Rys. 4.1: Rozkład czasu wykonania między narzędziami (opracowanie własne)

Największy udział w czasie wykonania mają:

1. pobieranie danych GloFAS (45%) – transfer plików GeoTIFF z serwera Copernicus,
2. pobieranie danych Overture (30%) – zapytania SQL do MotherDuck, zależne od liczby obiektów,
3. pobieranie granic (12%) – zapytania do Nominatim i Overpass API,
4. analiza przestrzenna (8%) – zależna od liczby obiektów,
5. rozumowanie LLM (5%) – planowanie i generowanie odpowiedzi.

4.5 Podsumowanie testów

Tabela 4.4 przedstawia podsumowanie wyników testów względem wymagań.

Tabela 4.4: Podsumowanie wyników testów (opracowanie własne)

Wymaganie	Kryterium	Wynik	Status
RN-01	Czas odpowiedzi ≤ 30 s	87,5% ≤ 30 s	PASS
RN-02	Interpretacja NL $\geq 80\%$	80%	PASS
RF-01–RF-08	Wymagania funkcjonalne	93,3% (14/15)	PASS

Wnioski z testów:

1. system spełnia wszystkie wymagania niefunkcjonalne (RN-01, RN-02),
2. 93,3% scenariuszy funkcjonalnych zakończonych sukcesem,
3. wskaźnik interpretacji języka naturalnego (80%) spełnia wymaganie RN-02,
4. wąskie gardło wydajności stanowi transfer danych GeoTIFF z serwera Copernicus (45% czasu),
5. główne ograniczenie: czas `get_overture_data` dla dużej liczby obiektów ($>100\,000$) – scenariusz Kraków (30,2 s samego zapytania).

Wnioski

Na podstawie przeprowadzonych prac nad systemem RiskScoop AI sformułowano następujące wnioski:

1. **skuteczność agentów AI** – duże modele językowe upraszczają interakcję użytkownika z systemem analizy geoprzestrzennej – użytkownik nie musi znać składni GIS,
2. **wartość otwartych danych** – integracja z Overture Maps Foundation i Copernicus GloFAS pokazuje, że otwarte dane wystarczają do budowy użytecznych narzędzi analitycznych,
3. **architektura AgentOS** – wzorzec AgentOS z frameworka Agno upraszcza implementację – automatyczne generowanie API eliminuje ręczne definiowanie endpointów,
4. **model ryzyka** – klasyfikacja oparta na 5 klasach głębokości powodzi z danych GloFAS okazała się skuteczna w identyfikacji zagrożonej infrastruktury.

Ograniczenia pracy

- zależność od zewnętrznych API (Google Gemini, Copernicus CDS, Overture Maps),
- dane GloFAS reprezentują scenariusze modelowe, nie rzeczywiste bieżące zagrożenie,
- brak walidacji modelu z danymi historycznymi o rzeczywistych stratach powodziowych.

Kierunki dalszych prac

1. integracja z polskim systemem ISOK i danymi IMGW,
2. rozbudowa modelu o współczynniki podatności infrastruktury,
3. generowanie raportów PDF dla potrzeb zarządzania kryzysowego,
4. powiadomienia o zmianie poziomu ryzyka w czasie rzeczywistym.

Podsumowanie

Praca przedstawiła projekt i implementację systemu RiskScoop AI – narzędzia do analizy ryzyka powodziowego z wykorzystaniem agenta AI.

Realizacja celów pracy

Wszystkie cele zdefiniowane we wstępie zostały zrealizowane:

1. **cel główny** – opracowano działający system analizy ryzyka powodziowego z interfejsem w języku naturalnym,
2. **cele szczegółowe:**
 - zaprojektowano architekturę agenta AI z 6 narzędziami,
 - zintegrowano dane Overture Maps, Copernicus GloFAS i OpenStreetMap,
 - zaimplementowano model klasyfikacji ryzyka,
 - stworzono responsywny interfejs z mapą Mapbox.

Weryfikacja kryteriów sukcesu

Wszystkie kryteria sukcesu zdefiniowane w rozdziale „Cel i zakres pracy” zostały spełnione:

- interpretacja języka naturalnego: **80%** (wymagane $\geq 80\%$),
- czas odpowiedzi: **90% zapytań $\leq 30s$** (wymagane $\leq 30s$),
- identyfikacja obiektów: zgodna z danymi Overture Maps,
- kwantyfikacja ryzyka: oparta na danych GloFAS,
- interfejs użytkownika: intuicyjny, z filtrowaniem i wizualizacją.

Główne osiągnięcia

1. agent AI z AgentOS i modelem Gemini 3 Pro,
2. 6 narzędzi do analizy geoprzestrzennej,
3. algorytm `assemble_rings` do rekonstrukcji granic z OSM,
4. integracja trzech źródeł danych geoprzestrzennych,
5. interfejs użytkownika z mapą interaktywną.

Praktyczne zastosowania

System może znaleźć zastosowanie w:

- zarządzaniu kryzysowym – ocena zagrożeń dla infrastruktury,
- planowaniu przestrzennym – identyfikacja obszarów ryzyka,
- ubezpieczeniach – szacowanie ekspozycji na ryzyko powodziowe.

Zrealizowany prototyp pokazuje, że agenci AI w połączeniu z otwartymi danymi geoprzestrzennymi pozwalają budować narzędzia analityczne dostępne dla użytkowników bez wiedzy technicznej.

Bibliografia

- [1] Agno AGI. *Agno: Multi-agent framework, runtime and control plane*. GitHub: 35k+ stars. Formerly known as Phi-data. 2024. URL: <https://github.com/agno-agi/agno> (term. wiz. 01.12.2024).
- [2] Ekene Chukwuma i in. "Flood Risk Analysis for Critical Infrastructure Protection". W: *Current Perspectives in Environmental Science*. IntechOpen, 2021. URL: <https://www.intechopen.com/chapters/75885> (term. wiz. 01.12.2024).
- [3] Copernicus Emergency Management Service. *Copernicus EMS and crisis maps production*. 2024. URL: <https://emergency.copernicus.eu/mapping> (term. wiz. 01.12.2024).
- [4] Copernicus Emergency Management Service. *Global Flood Awareness System (GloFAS) Documentation*. 2024. URL: <https://global-flood.emergency.copernicus.eu> (term. wiz. 01.12.2024).
- [5] First Street Foundation. "Flood Factor: Mapping flood risk with Mapbox". W: *Mapbox Blog* (2020). URL: <https://www.mapbox.com/blog/flood-factor> (term. wiz. 01.12.2024).
- [6] Huan Gong, Zhenlong Li i in. "An autonomous GIS agent framework for geospatial data retrieval". W: *International Journal of Digital Earth* 18.1 (2025). URL: <https://www.tandfonline.com/doi/full/10.1080/17538947.2024.2442956> (term. wiz. 01.12.2024).
- [7] Google Research. "Geospatial Reasoning: Unlocking insights with generative AI and multiple foundation models". W: *Google Research Blog* (2024). URL: <https://research.google/blog/geospatial-reasoning/> (term. wiz. 01.12.2024).
- [8] Joint Research Centre. *Global Flood Awareness System (GloFAS)*. Spraw. tech. European Commission, 2020. URL: <https://global-flood.emergency.copernicus.eu/> (term. wiz. 01.12.2024).
- [9] Elco Koks i in. "A global multi-hazard risk analysis of road and railway infrastructure assets". W: *Nature Communications* 10 (2019), s. 2677. URL: <https://www.nature.com/articles/s41467-019-10442-3> (term. wiz. 01.12.2024).
- [10] Zhenlong Li, Huan Ning i in. "ChatGeoAI: Enabling Geospatial Analysis for Public through Natural Language, with Large Language Models". W: *ISPRS International Journal of Geo-Information* 13.10 (2024), s. 348. DOI: 10.3390/ijgi13100348. URL: <https://www.mdpi.com/2220-9964/13/10/348> (term. wiz. 01.12.2024).
- [11] Zhenlong Li i in. "An LLM Agent for Automatic Geospatial Data Analysis". W: *arXiv preprint arXiv:2410.18792* (2024). URL: <https://arxiv.org/abs/2410.18792> (term. wiz. 01.12.2024).

- [12] Overture Maps Foundation. *Overture Maps Foundation Releases General Availability*. 2024. URL: <https://overturemaps.org/overture-maps-foundation-releases-first-world-wide-open-map-dataset/> (term. wiz. 01.12.2024).
- [13] Maria Pregnotato i in. "Bridge-specific flood risk assessment of transport networks using GIS". W: *Science of The Total Environment* 850 (2022), s. 157976. URL: <https://www.sciencedirect.com/science/article/pii/S0048969722051567> (term. wiz. 01.12.2024).
- [14] Yifan Rao i in. "GeoGPT: An assistant for understanding and processing geospatial tasks". W: *International Journal of Geographical Information Science* (2024). URL: <https://www.tandfonline.com/doi/full/10.1080/13658816.2024.2445026> (term. wiz. 01.12.2024).
- [15] United Nations Office for Disaster Risk Reduction. *Global Assessment Report on Disaster Risk Reduction*. Spraw. tech. UNDRR, 2022. URL: <https://www.undrr.org/gar/gar2022-our-world-risk-gar> (term. wiz. 01.12.2024).
- [16] Muhammad Waleed i in. "Advancing flood susceptibility prediction: A comparative assessment of machine learning algorithms". W: *Journal of Flood Risk Management* (2025). URL: <https://onlinelibrary.wiley.com/doi/10.1111/jfr3.13037> (term. wiz. 01.12.2024).
- [17] World Meteorological Organization. *WMO Atlas of Mortality and Economic Losses from Weather, Climate and Water Extremes (1970–2019)*. Spraw. tech. WMO-No. 1267. WMO, 2021. URL: <https://library.wmo.int/idurl/4/57564> (term. wiz. 01.12.2024).

Spis rysunków

2.1	Architektura systemu RiskScoop AI (opracowanie własne)	16
2.2	Diagram komponentów systemu (opracowanie własne)	17
2.3	Diagram sekwencji dla zapytania o ryzyko powodziowe (opracowanie własne) .	20
2.4	Projekt interfejsu użytkownika (opracowanie własne)	22
3.1	Przykład analizy: szpitale w Genewie (opracowanie własne)	29
3.2	Przykład analizy: szkoły w Warszawie (opracowanie własne)	30
3.3	Przykład analizy: budynki w Krakowie (opracowanie własne)	31
3.4	Przykład analizy: infrastruktura w okolicach Płocka (opracowanie własne) . . .	32
3.5	Przykład analizy: infrastruktura we Wrocławiu (opracowanie własne)	33
4.1	Rozkład czasu wykonania między narzędziami (opracowanie własne)	38

Spis tabel

1.1	Porównanie frameworków agentów AI w analizie geoprzestrzennej	8
1.2	Klasy głębokości GloFAS [4]	9
1.3	Porównanie konkurencyjnych rozwiązań	12
2.1	Wymagania funkcjonalne systemu (opracowanie własne)	15
2.2	Wymagania нефункционалне systemu (opracowanie własne)	15
2.3	Specyfikacja narzędzi agenta (opracowanie własne)	18
2.4	Klasyfikacja poziomu ryzyka (opracowanie własne)	21
4.1	Scenariusze testowe (opracowanie własne)	35
4.2	Testy interpretacji języka naturalnego (opracowanie własne)	36
4.3	Wyniki testów wydajnościowych (opracowanie własne)	37
4.4	Podsumowanie wyników testów (opracowanie własne)	39

Wykaz skrótów

AI	Artificial Intelligence (sztuczna inteligencja)
API	Application Programming Interface (interfejs programistyczny)
AOI	Area of Interest (obszar zainteresowania)
CEMS	Copernicus Emergency Management Service
CDS	Climate Data Store
GeoJSON	Geographic JavaScript Object Notation
GeoTIFF	Geographic Tagged Image File Format
GIS	Geographic Information System (system informacji geograficznej)
GloFAS	Global Flood Awareness System
HTTP	Hypertext Transfer Protocol
LLM	Large Language Model (duży model językowy)
OSM	OpenStreetMap
POI	Point of Interest (punkt zainteresowania)
REST	Representational State Transfer
RP	Return Period (okres powrotny)
UUID	Universally Unique Identifier

Wykaz definicji

Agent AI Program komputerowy wykorzystujący duży model językowy (LLM) do autonomicznego wykonywania zadań poprzez wybór i sekwencjonowanie dostępnych narzędzi.

AgentOS Wzorzec architektoniczny z frameworka Agno, który automatycznie generuje aplikację FastAPI z endpointami dla agenta AI.

Analiza przestrzenna Metoda analizy danych geograficznych polegająca na badaniu relacji przestrzennych między obiektami (np. przecięcia, odległości, zawieranie).

Bounding box Prostokątny obszar definiowany przez współrzędne narożników (minX, minY, maxX, maxY), używany do filtrowania danych przestrzennych.

Geokodowanie Proces konwersji adresów lub nazw miejscowości na współrzędne geograficzne.

GloFAS Globalny system wczesnego ostrzegania przed powodzią prowadzony przez Copernicus Emergency Management Service.

Okres powrotny Statystyczny czas między zdarzeniami o określonej skali (np. RP100 oznacza powódź występującą średnio raz na 100 lat).

Overture Maps Otwarty zbiór danych geograficznych tworzony przez konsorcjum firm technologicznych, zawierający budynki, POI i infrastrukturę.

Spatial Join Operacja łączenia zbiorów danych geograficznych na podstawie relacji przestrzennych (np. przecięcia geometrii).

Tool (narzędzie) Funkcja Python z dekoratorem @tool, którą agent AI może wywołać w celu wykonania określonego zadania.

Wykaz załączników

Załącznik A Kod źródłowy systemu RiskScoop AI

- A.1 – Plik główny `my_os.py` (konfiguracja AgentOS)
- A.2 – Narzędzia agenta (`tools/*.py`)
- A.3 – Serwisy biznesowe (`services/*.py`)
- A.4 – Frontend (`test_frontend/index.html`)

Załącznik B Screenshoty interfejsu użytkownika

- B.1 – Analiza szpitali w Genewie (rys. 3.1)
- B.2 – Analiza szkół w Warszawie (rys. 3.2)
- B.3 – Analiza budynków w Krakowie (rys. 3.3)